Rechazo de Solicitudes Hipotecarias en Colorado

EYP3407 Tópicos Aplicados en Estadística — Trabajo final, caso 10 (HMDA 2019–2023)

Lucas González Álvaro Morales Celeste Romero Julian Vargas

10 de noviembre de 2026

1. Resumen ejecutivo

En este trabajo se analiza la predicción del rechazo en solicitudes de créditos hipotecarios para compra de vivienda en Colorado, utilizando los registros públicos de HMDA entre 2019 y 2023. Frente a una referencia constante basada en la tasa histórica de entrenamiento, comparamos tres procedimientos: regresión logística penalizada (M1), un árbol de clasificación podado (M2) y un ensamble mediante Gradient Boosting (M3). El ajuste y la selección de modelos se realizaron con los datos de 2019 a 2022 (310 131 solicitudes, 5.21 % rechazadas) mediante validación temporal de origen creciente, evaluando el desempeño final sobre los registros de 2023 (49 914 solicitudes, 5.67 % rechazadas). En la preparación de los datos se excluyeron variables posteriores a la resolución crediticia para evitar fuga de información.

En la evaluación final de 2023, M3 alcanzó el mejor desempeño con un log-loss de 0.1534 frente al 0.2179 de la referencia (reducción de 29.6 %; IC 95 % por bootstrap de instituciones: -0.0784 a -0.0513) y un AUC ROC de 0.840 (exacto: 0.8395). Con el umbral calculado en base a la composición en desarrollo de los datos (0.0521), el modelo detecta el 71.5 % (0.7151) de los rechazos con un VPP de 17.7 % (0.1765).

Sugerimos emplear el modelo como herramienta de priorización para ordenar expedientes por riesgo antes de la revisión manual, y no como regla de decisión automática. La mayor capacidad predictiva se concentra en la razón deuda-ingreso y en la institución financiera.

La principal limitación es que, el análisis es retrospectivo y se basa en expedientes con decisión cerrada, por lo que no mide incumplimiento de pago futuro ni efectos causales. Asimismo, el modelo pierde fiabilidad en el subgrupo «NA / Exempt», donde la capacidad de discriminación decae notablemente.

Palabras clave: HMDA, clasificación binaria, validación temporal, reproducibilidad, Python, Scikit-learn, Rolling origin cross-validation

2. Problema y datos

2.1. Formulación del problema, audiencia y decisión

El objetivo de este trabajo es evaluar qué tan bien permiten los datos financieros del solicitante y las características de la propiedad predecir si una solicitud de crédito hipotecario para comprar una vivienda en Colorado será rechazada o aprobada en un año posterior.

El análisis está pensado para analistas de riesgo de instituciones financieras y organismos reguladores. Para las entidades que entregan créditos, este tipo de modelos ayuda a entender mejor los factores asociados al rechazo antes de procesar todo el expediente. Desde el punto de vista regulatorio, sirve

para comparar qué tan parejos son los criterios de aprobación entre los distintos bancos e instituciones del mercado.

La población de estudio incluye solo solicitudes de crédito para compra de vivienda en Colorado entre 2019 y 2023, que correspondan a préstamos convencionales, primera hipoteca, vivienda principal de una sola unidad y construcción tradicional. Siguiendo las definiciones del caso, quedan fuera las hipotecas inversas, las líneas de crédito abiertas y los préstamos comerciales.

La unidad de observación es una solicitud individual registrada en la base HMDA, identificada mediante la combinación de `activity_year` y `fila_fuente`. Las variables predictoras son aquellas que ya estaban disponibles al momento de postular: el ingreso del solicitante, el monto pedido, el valor tasado de la vivienda, el plazo del crédito, las razones préstamo–valor y deuda–ingreso, el condado y el código de la institución financiera (`lei`).

En términos metodológicos, el problema se aborda como una clasificación binaria retrospectiva sobre solicitudes que tuvieron una decisión final cerrada (crédito entregado, aprobado pero no tomado, o rechazado). Es importante aclarar que el modelo no mide si la persona va a pagar o caer en mora más adelante, no incluye solicitudes que fueron retiradas antes de tiempo, y las relaciones encontradas son asociaciones predictivas, no relaciones de causa y efecto.

Procedencia de los datos. La información proviene del Home Mortgage Disclosure Act (HMDA), publicado por la FFIEC y la CFPB. Se utiliza el paquete oficial del curso `caso10_hmda_colorado.zip` (copia obtenida el 12-10-2026 desde el HMDA Data Browser para Colorado 2019–2023), compuesto por `solicitudes_hmda.csv` (360 045 filas, 100 columnas y 1 076 instituciones), `diccionario.csv` y `LEEME.txt`. Los archivos originales no fueron modificados. Según se especifica en el `LEEME.txt`, el campo `loan_to_value_ratio` corresponde a `combined_loan_to_value_ratio` en el diccionario estándar.

La variable de respuesta binaria (Y) se define a partir del campo administrativo `action_taken`:

$$Y = \begin{cases} 1 & \text{si } \texttt{action_taken} = 3 \quad \text{(Solicitud rechazada)}, \\ 0 & \text{si } \texttt{action_taken} \in \{1, 2\} \quad \text{(Crédito originado o aprobado no ejercido)}. \end{cases} \tag{1}$$

Predecimos la decisión de un año calendario completo utilizando exclusivamente modelos entrenados con años anteriores. Debido a que la base pública no registra fechas internas dentro del año (como mes o día de ingreso), no es posible plantear cortes temporales intranuales. Las solicitudes retiradas o cerradas por falta de antecedentes no se imputan ni se reagrupan artificialmente, pues su desenlace no constituye una evaluación de riesgo formal por parte de la entidad.

La Figura 1 resume el flujo del estado inicial de los datos considerando filtros y separación de ventanas temporales para entrenamiento, validación y reserva final. Asimismo, la Tabla 1 detalla una verificación que confirma que el archivo provisto ya contenía el recorte preestablecido de la población de estudio, logrando retener el 100 % de las 360 045 solicitudes iniciales sin necesidad de mayores exclusiones adicionales.

Tabla 1: Construcción de la muestra: filas, exclusiones, rechazos e instituciones tras cada filtro.

Paso	Criterio	Filas	Excluidas	Rechazos	Instituciones
0. Archivo entregado	—	360 045	0	18 985	1 076
1. Préstamo convencional	`loan_type` = 1	360 045	0	18 985	1 076
2. Compra de vivienda	`loan_purpose` = 1	360 045	0	18 985	1 076
3. Primera hipoteca	`lien_status` = 1	360 045	0	18 985	1 076
4. Vivienda principal	`occupancy_type` = 1	360 045	0	18 985	1 076
5. Una unidad	`total_units` = 1	360 045	0	18 985	1 076
6. Construcción tradicional	`construction_method` = 1	360 045	0	18 985	1 076
7. Sin hipoteca inversa	`reverse_mortgage` = 2	360 045	0	18 985	1 076
8. Sin línea de crédito	`open-end_line_of_credit` = 2	360 045	0	18 985	1 076
9. Sin propósito comercial	`business_or_commercial_purpose` = 2	360 045	0	18 985	1 076
10. Decisión registrada	`action_taken` $\in \{1, 2, 3\}$	360 045	0	18 985	1 076

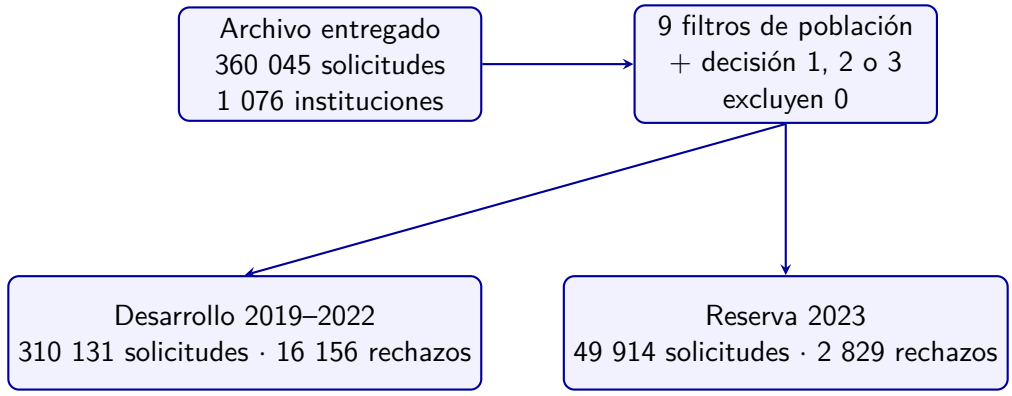


Figura 1: Construcción de la muestra. El archivo entregado ya venía recortado a la población del caso: los filtros se verifican sin excluir filas (Tabla 1).

2.2. Auditoría de datos y predictores admisibles

Para evitar fuga de información (*data leakage*), revisamos rigurosamente las 100 columnas de la base (Tabla 2). Se excluyen la decisión y sus motivos, el comprador del crédito, tasas, costos y condiciones que solo existen si el crédito se aprueba, además de los diagnósticos de sistemas automatizados (AUS), pues son posteriores a la decisión o la revelan directamente. Las variables demográficas se descartan por ser atributos protegidos ajenos a la evaluación financiera. Los predictores que fueron modificados y los mas influyentes a primera vista (finalmente empleados) corresponden a los candidatos de la ficha del caso (Tabla 3).

Tabla 2: Auditoría de columnas por familia conceptual. †Valor final revisado por la institución.

Familia	n	Columnas	Disponibilidad	Decisión
Clave y partición	2	`fila_fuente`, `activity_year`	Técnica	No predictor
Institución	1	`lei`	Al ingresar	Incluida (codificada)
Condado	1	`county_code`	Al ingresar	Incluida (codificada)
Préstamo y vivienda	4	`loan_amount`, `loan_to_value_ratio`, …	Al ingresar†	Incluidas
Capacidad de pago	2	`income`, `debt_to_income_ratio`	Al ingresar†	Incluidas
Respuesta y motivos	5	`action_taken`, `denial_reason-1`, …	Posterior	Excluidas: revelan la respuesta
Evaluación automatizada (AUS)	5	`aus-1`, `aus-2`, …	Durante el proceso	Excluidas: fuga
Comprador del crédito	1	`purchaser_type`	Posterior	Excluida: fuga
Precio, costos y condiciones	14	`interest_rate`, `rate_spread`, …	Posterior	Excluidas: fuga
Definen la población	14	`derived_loan_product_type`, `derived_dwelling_category`, …	—	Excluidas: constantes
Geografía redundante	3	`derived_msa-md`, `state_code`, …	Al ingresar	Excluidas: redundantes
Proceso, canal y tipo de puntaje	6	`conforming_loan_limit`, `preapproval`, …	Incierta	Excluidas: fuera de la ficha
Demográficas	35	`derived_ethnicity`, `derived_race`, …	Al ingresar	Excluidas: atributos protegidos
Contexto censal	7	`tract_population`, `tract_minority_population_percent`, …	Externa	Excluidas: fuera de la ficha

Tabla 3: Predictores usados y su construcción (ajustada dentro de cada partición).

Predictor	Interpretación	Tipo y unidad	Construcción
`income`	Ingreso anual	Numérico, miles USD	Imputación por mediana, estandarización
`loan_amount`	Monto solicitado	Numérico, USD	Imputación por mediana, estandarización
`property_value`	Valor de la vivienda	Numérico, USD	Mediana, estandarización
`loan_term`	Plazo	Numérico, meses	Mediana, estandarización
`loan_to_value_ratio`	Razón préstamo–valor	Numérico, %	Mediana, estandarización
`dti_numerico`	Razón deuda–ingreso	Intervalos a punto medio (15, 25, 33, 55, 65)	`NA`/`Exempt` a mediana
`lti_ratio` (derivada)	Monto / (ingreso × 1000)	Numérico, veces	Mediana, estandarización
`lei`	Institución	Categórico	Tasa de rechazo de entrenamiento; nueva → tasa global
`county_code`	Condado	Categórico	Igual que `lei`

Calidad de los datos: Los registros `NA` y `Exempt` no se convierten en cero, sino que se tratan como datos faltantes y se imputan con la mediana observada en el entrenamiento (Tabla 4). En desarrollo detectamos 1 198 ingresos ≤ 0 y 17 razones préstamo-valor mayores al 150 %; decidimos conservarlos

debido a que la estandarización y los árboles toleran observaciones extremas plausibles, y no hay justificación para considerarlos errores de digitación. Ninguna fila se descarta.

Tabla 4: Valores faltantes tras la conversión numérica (desarrollo 2019–2022).

Variable	Nulos 2019–2022	%
`lti_ratio`	4 024	1.30 %
`income`	2 965	0.96 %
`loan_to_value_ratio`	1 934	0.62 %
`dti_numerico`	1 773	0.57 %
`property_value`	1 662	0.54 %
`county_code`	649	0.21 %
`loan_term`	359	0.12 %

Descripción de la muestra: La Tabla 5 muestra que la tasa de rechazo oscila entre periodos y que la composición de los prestamistas es dinámica. En el conjunto de desarrollo operan 998 instituciones; las 15 más grandes concentran el 42.0 % de las solicitudes y, entre aquellas con al menos 500 operaciones, la tasa de rechazo varía entre 0.0 % y 35.0 %. Por su parte, en 2023 ingresan 78 instituciones no observadas en desarrollo (0.8 % de las solicitudes).

Tabla 5: Solicitudes, rechazos e instituciones por año.

Año	Conjunto	Solicitudes	Rechazos	Tasa	Instituciones	Inst. nuevas
2019	Desarrollo	73 518	4 079	5.55 %	615	—
2020	Desarrollo	79 446	4 181	5.26 %	632	153
2021	Desarrollo	87 583	4 162	4.75 %	674	123
2022	Desarrollo	69 584	3 734	5.37 %	702	107
2023	Prueba	49 914	2 829	5.67 %	630	78

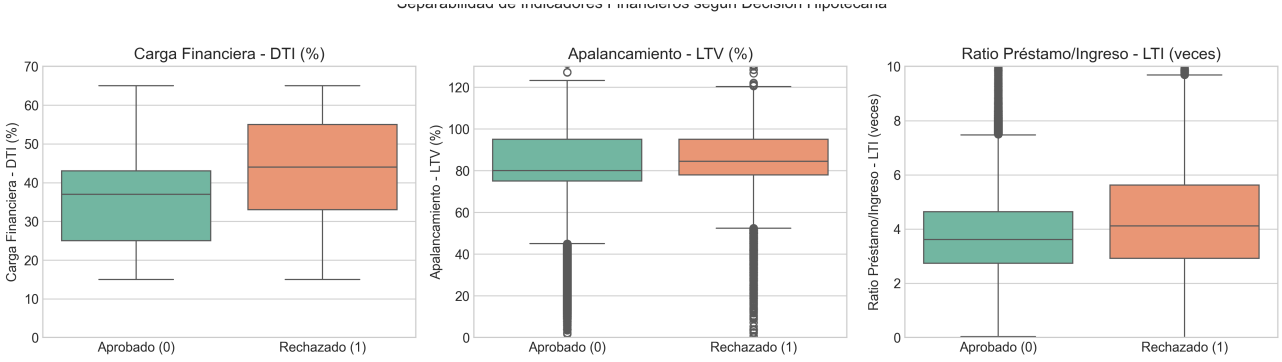


Figura 2: Distribución de DTI, LTV y razón monto-ingreso según la decisión (2019–2022). Los rechazos tienen DTI y LTV más altos, pero con gran traslape: ninguna variable por sí sola separa las clases.

3. Diseño de evaluación

Para evaluar los procedimientos de forma realista y coherente con el uso operativo previsto, dividimos los datos respetando la secuencia anual de los registros. El periodo total abarca cinco años: los años 2019 a 2022 conforman el conjunto de desarrollo (310 131 solicitudes), reservando íntegramente el año 2023 (49 914 solicitudes) como conjunto de prueba independiente para una única evaluación final.

Descartamos el uso de una partición aleatoria convencional (como una validación cruzada tradicional de k-folds sobre todas las filas). En este contexto, una partición al azar mezclaría solicitudes resueltas en el futuro con expedientes pasados y violaría el supuesto de independencia, ya que solicitudes tramitadas por una misma institución bancaria comparten directrices y criterios de crédito comunes. Además, el objetivo práctico del modelo es predecir las resoluciones de un ciclo anual posterior disponiendo únicamente del historial acumulado hasta ese momento.
Dentro de la fase de desarrollo, la comparación interna de modelos y la calibración de hiperparámetros se implementaron mediante un esquema de validación cruzada de origen móvil (*rolling origin cross-validation*) con tres ventanas temporales expansivas (Figura 3):

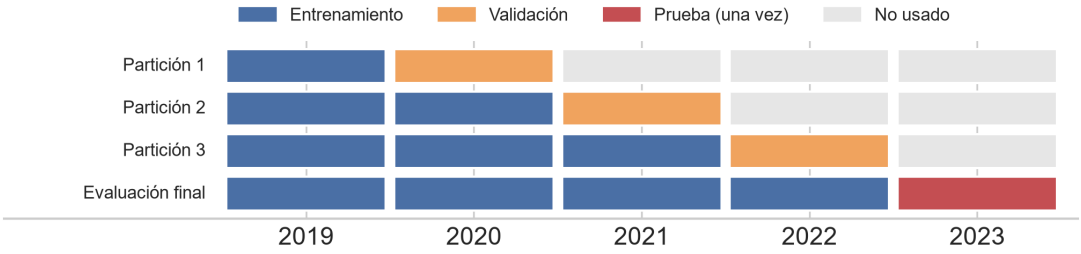


Figura 3: Esquema temporal: ventana expansiva en desarrollo y evaluación única en 2023.

Este diseño permite aplicar una metodología adecuada para datos con estructura temporal. Se previene la fuga de datos (data leakage) debido a que la estructura del modelo nunca entrena con información del futuro para predecir el pasado. Asimismo presenta una simulación realista (Backtesting), imitando cómo operaría el modelo en producción al actualizarse periódicamente con nueva información, entre otros.

Dado que cada fila del archivo representa un expediente con su resolución ya concluida dentro del mismo año calendario, no existen desfases temporales ni horizontes que crucen artificialmente los puntos de corte entre años.

3.1. Información admisible y prevención de fuga en el flujo

Para asegurar que ninguna etapa de preparación de datos contamine los conjuntos de validación o prueba con información futura, todo el preprocesamiento se encapsuló en un `Pipeline` estructurado:

1. **Imputación y estandarización:** Los valores ausentes de variables cuantitativas (`income`, `property_value`, `loan_term`, `loan_to_value_ratio`, `dti_numerico` y `lti_ratio`) se completan usando exclusivamente la mediana calculada en el bloque de entrenamiento correspondiente. De igual forma, la media y desviación estándar para el escalamiento de variables continuas se obtienen únicamente de los datos de entrenamiento.
2. **Codificación por tasa objetivo (*target encoding*):** La tasa histórica de rechazo para cada institución (`lei`) y condado (`county_code`) se estima estrictamente sobre las observaciones de entrenamiento de cada partición.
3. **Manejo de entidades nuevas:** A aquellas instituciones o condados que no registraron actividad en los años previos y aparecen por primera vez en la ventana de evaluación, se les asigna de forma determinista la prevalencia global de rechazo observada en el entrenamiento histórico respectivo ($\bar{Y}_{\text{train}}$), sin consultar jamás sus etiquetas reales.

3.2. Métricas de evaluación, regla de decisión y línea base

Dado el desbalance de clases (los rechazos rondan el 5 %) y el objetivo de priorizar solicitudes según riesgo, evaluamos los modelos mediante métricas probabilísticas y de clasificación:

Métrica principal: Pérdida logarítmica (*log-loss*). Penaliza la incertidumbre y mide la calibración de las probabilidades asignadas. El procedimiento ganador en desarrollo se definió como aquel con el menor log-loss promedio en las tres ventanas temporales (2020, 2021 y 2022).

Métricas complementarias: Puntaje de Brier (error cuadrático de las probabilidades), AUC-ROC (capacidad de ordenamiento global independiente del umbral), y para evaluar la clasificación binaria operativa, Sensibilidad y Valor Predictivo Positivo (VPP) resumidos mediante la matriz de confusión.

Umbral operativo y regla de decisión: Debido al desbalance, el umbral estándar de 0,50 no clasifica alertas. Por ello, el umbral se calcula dinámicamente a partir de los datos de entrenamiento, siendo la tasa marginal de rechazo observada en el entrenamiento histórico (0.0521), priorizando la detección temprana de rechazos. Cabe recalcar que existe la opción de poder elegir un umbral de corte fijo, pero es totalmente exploratorio ya que no sería optimo teniendo en cuenta con el desbalance actual de los datos.

Línea base de referencia: Se definió una predicción probabilística constante igual a la tasa histórica de rechazo del entrenamiento ($\widehat{p}_{\text{ref}} = \bar{Y}_{\text{train}}$). Un modelo solo se considera útil si mejora significativamente el log-loss frente a esta referencia.

4. Métodos

4.1. Familias de modelos y expectativas previas

Comparamos tres procedimientos con distinto nivel de flexibilidad frente a la referencia de tasa constante:

- **M1 - Regresión Logística Penalizada (Ridge, L_2):** Asume efectos lineales y aditivos en el logit sobre variables estandarizadas. Esperábamos un modelo interpretable y rápido, pero con limitaciones para capturar interacciones o los cambios bruscos de rechazo en niveles críticos de endeudamiento (como el salto sobre el 50 % en DTI).
- **M2 - Árbol de Clasificación Podado (CART):** Genera particiones ortogonales sucesivas minimizando la impureza de Gini. Se prefirió frente a una SVM porque entrega probabilidades directas en las hojas sin necesidad de calibración adicional. Esperábamos que capturara umbrales simples de riesgo, aunque con probabilidades escalonadas que suelen castigar el log-loss.
- **M3 - Gradient Boosting (`GradientBoostingClassifier`):** Ensamble secuencial de árboles de decisión que corrige iterativamente los residuos de la pérdida logarítmica mediante descenso de gradiente. Anticipábamos el mejor log-loss global al modelar relaciones no lineales e interacciones complejas, vigilando que no sobreajustara en prestamistas con pocas solicitudes.

4.2. Búsqueda de hiperparámetros y selección interna

Definimos una grilla acotada de búsqueda (máximo 16 combinaciones por familia) para asegurar reproducibilidad y eficiencia computacional:

- **M1:** Regularización $C \in \{0{,}001;\ 0{,}01;\ 0{,}1;\ 1;\ 10\}$ (5 configuraciones) con optimizador `lbfgs`.
- **M2:** Profundidad máxima $\in \{4, 6, 8, 10\}$ combinada con muestras mínimas por hoja $\in \{50, 100, 250, 500\}$ (16 configuraciones).
- **M3:** Número de árboles $\in \{50, 100\}$, tasa de aprendizaje $\in \{0{,}05;\ 0{,}10\}$ y profundidad $\in \{3, 5\}$ (8 configuraciones).

Para la selección interna, las filas de entrenamiento de cada ventana se ordenaron en el tiempo: el primer 80 % se usó para el ajuste inicial y el 20 % final (las solicitudes más recientes del bloque) para elegir los hiperparámetros con mayor AUC-ROC. Con la configuración ganadora definida, el modelo se reentrenó con el 100 % del bloque histórico antes de evaluar el año de validación siguiente. Las configuraciones elegidas se detallan en el anexo (Tabla 10); para la prueba final de 2023 se utilizó la combinación seleccionada en la ventana de 2022.

5. Resultados

5.1. Desarrollo (validaciones 2020, 2021 y 2022)

Tabla 6: Desarrollo: media de las tres validaciones. ΔLL es la diferencia con la referencia en las mismas filas; el rango muestra el mínimo y el máximo entre años. Sensibilidad y VPP con umbral igual a la tasa de entrenamiento.

Modelo	Log-loss	DE	ΔLL	Rango ΔLL	Brier	AUC	Sens.	VPP
Referencia	0.2023	0.0094	—	—	0.0487	0.500	—	—
M1 Logística L2	0.1721	0.0096	-0.0303	[-0.0314; -0.0289]	0.0431	0.770	68.1 %	12.5 %
M2 Árbol podado	0.1597	0.0189	-0.0426	[-0.0519; -0.0291]	0.0365	0.828	72.2 %	15.0 %
M3 Gradient boosting	0.1396	0.0074	-0.0627	[-0.0666; -0.0603]	0.0343	0.849	71.8 %	16.9 %

El menor log-loss medio fue el de M3 Gradient boosting (0.1396 para M3, frente a 0.1721 de M1, 0.1597 de M2 y 0.2023 de la referencia). La mejora de M3 sobre la referencia se observa en los tres años. Esa variación entre ventanas dependientes describe estabilidad, no un intervalo de confianza.

Los ajustes de los modelos y procesos iterativos, como los hiperparametros afectaban el desempeño y la sensibilidad:

- M1 (Regresión Logística): La gran colinealidad que presentaban entre monto, ingreso y valor de la propiedad obligó a la grilla optar por un valor de penalización más estricto ($C = 0.001$). Si en el caso contrario se optaba por disminuir la penalizacion ($C \geq 1$) o intentar compensar el desbalance mediante pesos inversamente proporcionales en pruebas exploratorias, las probabilidades entregadas por el modelo se inflaban de una manera artificial, empeorando el log-loss y gatillando el aumento de las falsas alarmas dentro de la matriz de confusión del modelo (sobre el 35 %)
- M2 (Árbol de Decisión): Si se permitían hojas pequeñas (min_samples_leaf = 50) dado la libertad del modelo terminaba por provocar un sobreajuste, lo que "memorizaba.[el] comportamiento de los bancos más pequeños. Para lograr una estabilidad y evitar generar errores extremos, se optó por configurarlo a usar grupos más grandes (100 a 500 obs.) estabilizando así el árbol, aunque esto provocó que sus predicciones se volvieran mas escalonadas.
- M3 (Gradient Boosting): Dentro de los modelos más consistentes, robustos y con un bajo tiempo computación en relacion a los otros modelos propuestos del mismo tipo. Su configuración ideal se mantuvo dentro (100 árboles, profundidad 5 y tasa de aprendizaje de 0.10) del correcto funcionamiento para las 3 ventanas temporales. Este permitió entender dinamicas complejas (como tener un mayor endeudamiento frente a bancos que son mas estrictos).

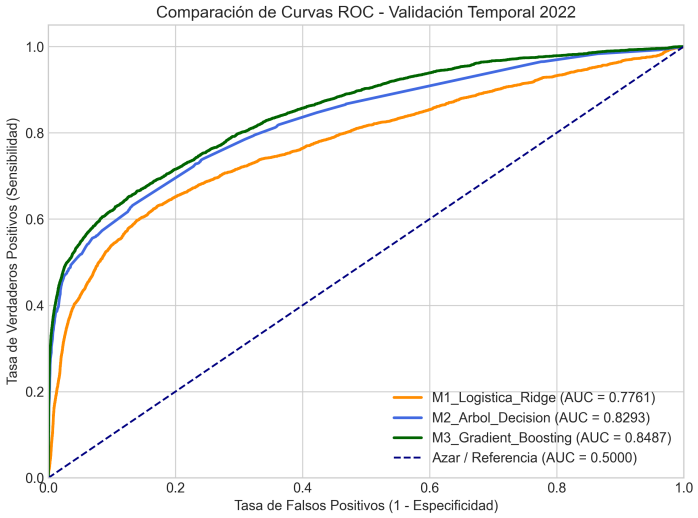


Figura 4: Curvas ROC en la validación 2022 (entrenamiento 2019–2021).

5.2. Comparativa, Matrices de Confusión entre M1 y M3 2022

La Figura 5 contrasta el desempeño del modelamiento en la validación de 2022 entre el modelo lineal penalizado (M1) y el ensamble de árboles (M3), evaluados bajo el mismo umbral histórico de entrenamiento ($p^* = 0.0516$). Si bien ambos procedimientos alcanzan una sensibilidad prácticamente idéntica cercana al 72 % (2 699 rechazos reales detectados por M1 frente a 2 689 por M3, equivalentes al 3.9 % del total de solicitudes), exhiben una gran diferencia en el control de la identificación de falsos positivos. La regresión logística (M1) genera 20 424 falsas alarmas (29.4 % de toda la cartera), mientras que Gradient Boosting (M3) las reduce a 13 600 (19.5 %), elevando los verdaderos negativos de 45 426 (65.3 %) a 52 250 (75.1 %). Esto permite descartar correctamente 6 824 casos sin perder la capacidad de captura sobre los rechazos verdaderos. Lo cual se refiere en un menor costo de chequeo de expedientes manuales en un caso hipotetico.

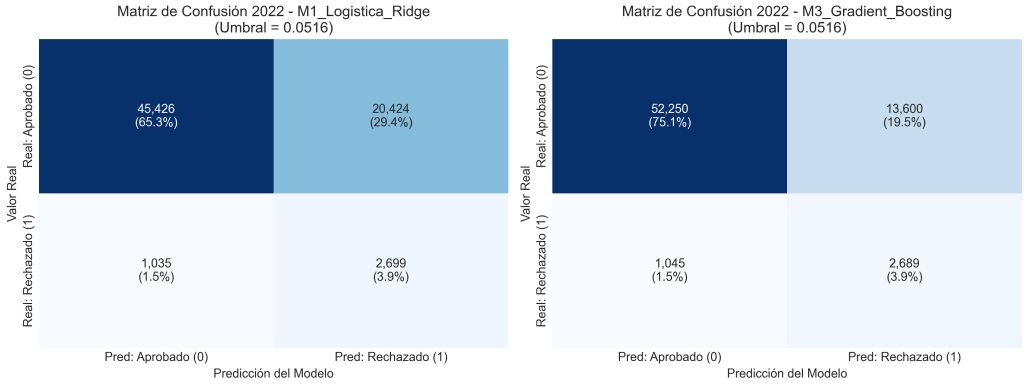


Figura 5: Matrices de confusión en la validación M1 y M3 2022 (entrenamiento 2019–2021).

5.3. Evaluación única en la reserva 2023

Los resultados obtenidos y analisis pertinentes de la evaluación final del segmento de reserva 2023 en base a graficos y tablas fueron los siguientes.

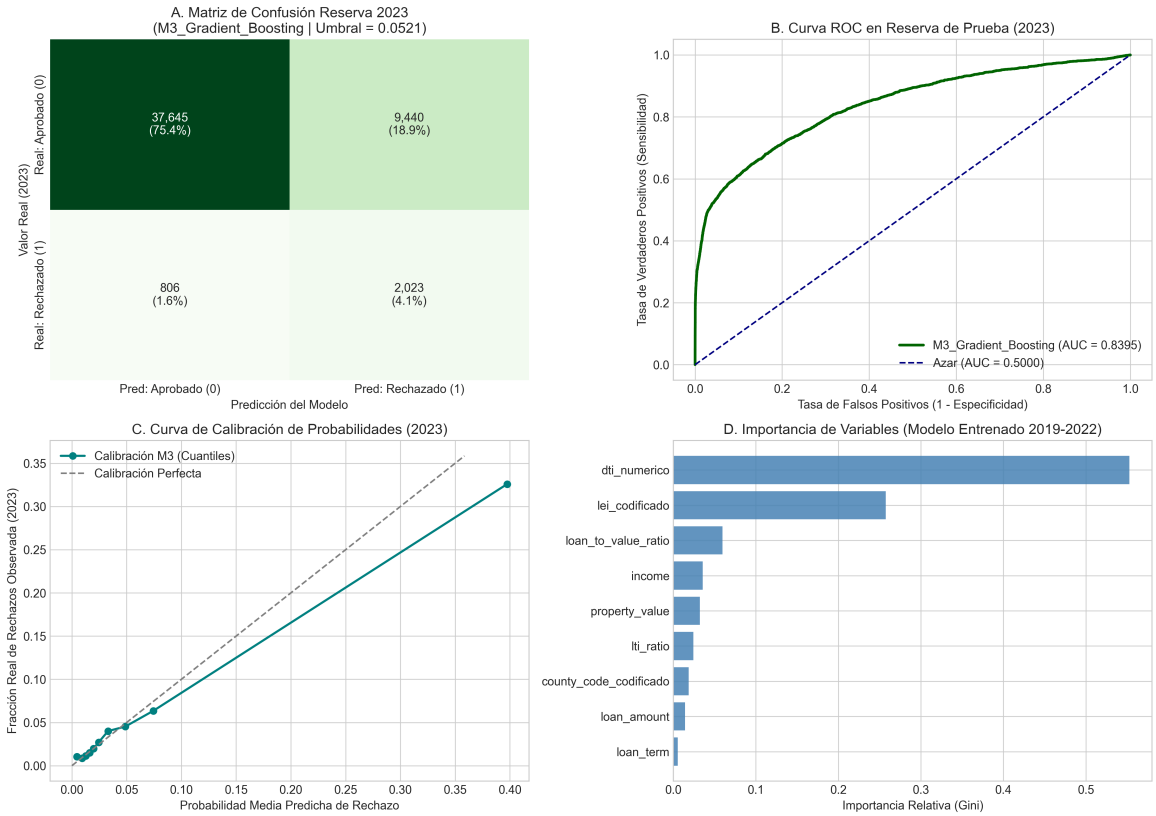


Figura 6: Diagnóstico de M3 en la reserva 2023: (A) matriz de confusión, (B) curva ROC, (C) calibración por deciles de probabilidad y (D) importancia de variables (Gini, modelo ajustado con 2019–2022).

Tabla 7: Reserva 2023 (49 914 solicitudes, 2 829 rechazos; mismas filas para todos los modelos). IC 95 %: bootstrap de 630 instituciones, 2 000 réplicas, predicciones fijas.

Modelo	Log-loss	ΔLL vs. ref. [IC 95 %]	Brier	AUC	Sens.	VPP	Alertas
Referencia	0.2179	—	0.0535	0.5000	—	—	—
M3 Gradient boosting	0.1534	-0.0645 [-0.0784; -0.0513]	0.0385	0.8395	71.5 %	17.7 %	23.0 %

M3 redujo el log-loss en 29.6 % respecto de la referencia (diferencia -0.0645; IC 95 % -0.0784 a -0.0513, que excluye el cero). Frente a M1, la diferencia fue -0.0363 (IC 95 % -0.0491 a -0.0242): la ventaja de M3 sobre la logística es estable entre instituciones. **Incertidumbre:** se remuestrean instituciones completas porque sus solicitudes comparten políticas y no son independientes. El intervalo es condicional a los modelos ajustados: no incluye la variabilidad de la selección ni del reentrenamiento. (Nota: La estimación de incertidumbre por bootstrap y los análisis de subgrupos se realizaron computacionalmente durante la etapa de investigación en cuadernos Jupyter, separando este costo computacional del flujo de ejecución final).

Con el umbral 0.0521, M3 marca el 23.0 % de las solicitudes: 2 023 rechazos detectados, 806 no detectados y 9 440 falsas alarmas (con 37 645 verdaderos negativos). Como el umbral es bajo, prioriza sensibilidad a costa del VPP; la Figura 8 muestra el compromiso. En 2023, la probabilidad media de M3 fue 6.4 % frente a una tasa observada de 5.7 % (el modelo sobreestima el rechazo); en el decil de mayor riesgo predijo 40.0 % y se observó 32.5 %.

5.4. Análisis de Umbral y Trade Off

Debido a la baja prevalencia de rechazos en nuestra variable objetivo es que resulta impreciso definir un umbral estándar en torno al $p^* = 0.50$ ya que maximizaría el Accuracy de una manera totalmente no realista si simplemente se considera clasificar cada muestra como aprobada y no aprovecharía la calidad de los métodos utilizados, es por eso que se debe ajustar un umbral en referencia a la tasa de rechazo observada en el entrenamiento, la cual oscila entre $\approx 5.21\,\%$ en desarrollo y $5.67\,\%$ en 2023. Por ello, se estableció como regla base fijar dinámicamente el umbral en la prevalencia histórica de entrenamiento ($p^* = 0.0516$ en 2022 y $p^* = 0.0521$ en 2023), alineando el punto de corte con la tasa marginal del evento raro.

Se logra observar en la Figura 8 que utilizar el umbral predefinido como referencia y punto de partida denota de gran manera cómo existe ese intercambio de disminuir sensibilidad frente un aumento de precisión en las alarmas.

En las Figuras 7 y 8 se observa que el compromiso (trade-off) de la sensibilidad es bastante notorio. Si se busca elevar el umbral de manera artificial para aumentar la precisión, el modelo comienza a perder sensibilidad, lo cual generaría falsos negativos (riesgos no detectados) y, con ello, un resultado erróneo de clasificación.

Dado esto, es importante recalcar que la implementación de estos modelos de clasificación para automatizar rechazos hipotecarios dentro de un entorno real representaría un gran riesgo.

Principales puntos a tomar en cuenta:

- **Optimización orientada a Sensibilidad:** Si se usa un umbral bajo (0.0521) para priorizar la captura temprana de rechazos, los resultados del modelo y la matriz de confusión indican que se rechazarían por error 9 440 clientes solventes en un periodo de un año. Es pertinente considerar que, para una empresa, perder esta cantidad de posibles negocios representa un grave problema de rentabilidad y reputación.
- **Optimización orientada a equilibrio armónico:** En el caso hipotético de aumentar el umbral (0.25) para elevar el VPP a $\approx 48\,\%$ y evitar la pérdida de clientes esenciales, se terminaría aprobando a más de la mitad de los perfiles que representan un riesgo sin haberlos identificado. Aunque esto reduce drásticamente las falsas alarmas, la sensibilidad del modelo también disminuye a $\approx 50\,\%$, dejando escapar sin revisión a la mitad de los rechazos reales.
- **Separación entre calibración y decisión:** Intentar optimizar métricas duras de clasificación (como F1-Score o exactitud balanceada) directamente durante el entrenamiento lograba, en gran medida, distorsionar el significado probabilístico de las predicciones. Por ello, se optó por mantener el log-loss y el AUC-ROC como criterios de ajuste en rangos estables. Esto permite obtener probabilidades bien ordenadas y balanceadas, delegando finalmente el cálculo y la elección del umbral p^* a la etapa operativa.

Los problemas financieros que causaría este modelo serían catastróficos si se empleara sin supervisión humana. Rechazar automáticamente las solicitudes que sobrepasen el umbral de 0.0521 provocaría el descarte de 9 440 clientes en un año (falsos positivos). En el caso contrario, si se aplica un umbral más alto, el sistema sería muy permisivo y no lograría detectar de manera efectiva los perfiles riesgosos. La gran ventaja de esta herramienta es que, en vez de tener que examinar a ciegas la totalidad masiva de la cartera (como las 360 045 solicitudes históricas), ahora solamente se deberían revisar en detalle los expedientes marcados como alerta por el algoritmo (aproximadamente un $23\,\%$ de las operaciones anuales), focalizando el esfuerzo humano y optimizando enormemente los recursos de la institución.

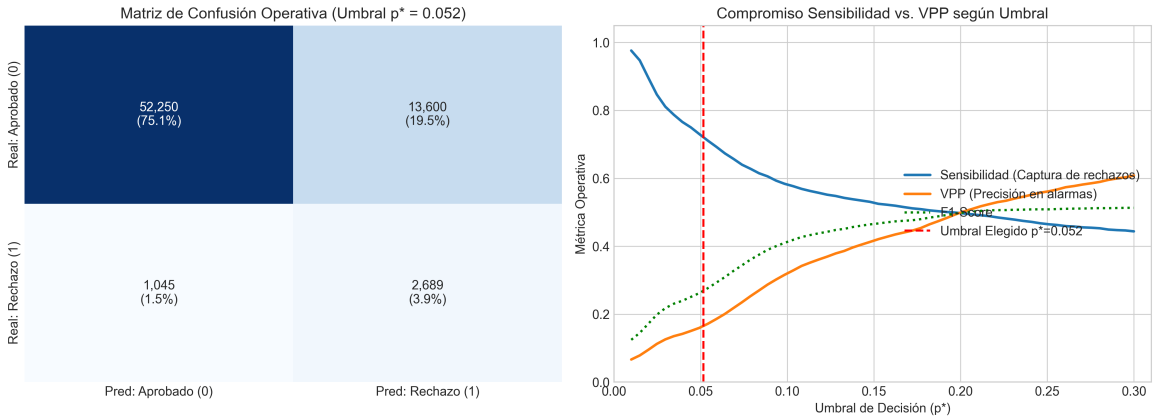


Figura 7: Matriz de Confusión y Trade Off M3 en validación 2022

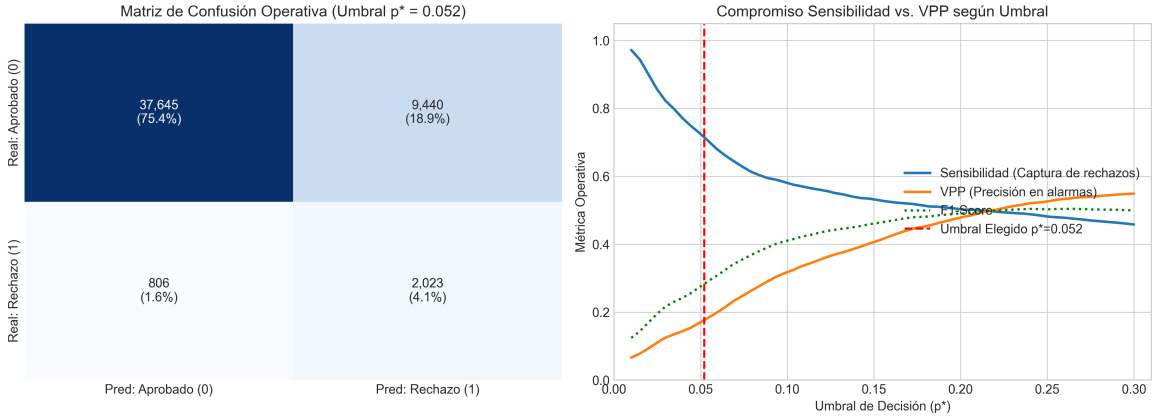


Figura 8: Matriz de Confusión y Trade Off M3 en reserva 2023

5.5. Análisis de errores

Tabla 8: M3 en la reserva 2023 por tamaño de la institución (solicitudes en desarrollo) y por tramo de DTI. AUC sólo con al menos 10 rechazos.

Dimensión	Subgrupo	n	Rech.	Tasa obs.	Prob. media	LL M3	LL ref.	AUC
Institución	Nueva (0 en desarrollo)	410	19	4.6 %	4.8 %	0.1236	0.1879	0.849
Institución	Pequeña (1–99)	3 661	259	7.1 %	9.4 %	0.2366	0.2587	0.770
Institución	Mediana (100–999)	8 520	574	6.7 %	8.0 %	0.1772	0.2490	0.855
Institución	Grande (≥1000)	37 323	1 977	5.3 %	5.8 %	0.1410	0.2072	0.845
DTI	<36 %	16 651	519	3.1 %	3.7 %	0.1223	0.1439	0.765
DTI	36–49 %	30 620	1 031	3.4 %	4.0 %	0.1393	0.1512	0.725
DTI	50–60 %	1 447	483	33.4 %	41.1 %	0.5736	1.0219	0.741
DTI	>60 %	933	714	76.5 %	76.8 %	0.3573	2.2737	0.920
DTI	NA / Exempt	263	82	31.2 %	20.1 %	0.8554	0.9581	0.559

La Tabla 8 muestra que los tramos de DTI sobre 50 % son poco frecuentes pero concentran los rechazos (eventos raros), allí la mejora frente a la referencia es grande, pero las probabilidades altas deben leerse como «revisar», no como certeza. **La recomendación no es confiable en el subgrupo «NA / Exempt»** (n = 263, 82 rechazos): el AUC baja a 0.559 y la probabilidad media (20.1 %)

difiere de la tasa observada (31.2 %). Como la DTI faltante se imputa con la mediana, el modelo no puede distinguir estos expedientes por su carga financiera. La importancia Gini (Figura 6D) muestra dependencia del modelo, no efectos causales, y se reparte entre predictores correlacionados (monto, valor y razón préstamo–valor).

5.6. Análisis de sensibilidad

Tabla 9: Sensibilidades en desarrollo (media de las tres validaciones, con la configuración elegida en cada año). Δ positivo indica peor log-loss.

Modelo	Especificación	Log-loss	Δ vs. principal	AUC
M1 Logística L2	Principal (DTI en punto medio, con institución)	0.1721	—	0.770
M1 Logística L2	S1: DTI como categoría	0.1514	-0.0207	0.832
M1 Logística L2	S2: sin institución	0.1838	+0.0118	0.685
M3 Gradient boosting	Principal (DTI en punto medio, con institución)	0.1396	—	0.849
M3 Gradient boosting	S1: DTI como categoría	0.1380	-0.0016	0.854
M3 Gradient boosting	S2: sin institución	0.1520	+0.0124	0.776

S1. Codificación de la razón deuda–ingreso (preparación de datos). En la especificación principal, la DTI se convierte al punto medio de cada intervalo y `NA`/`Exempt` se imputan con la mediana. En la alternativa se trata como categoría (intervalos, enteros 36–49, `NA` y `Exempt`), codificada con la tasa de rechazo de entrenamiento, igual que la institución. El log-loss cambia en -0.0207 para M1 y en -0.0016 para M3. Tratarla como categoría mejora a ambos, sobre todo a la logística, porque conserva la tasa alta de rechazo de la DTI `NA` y el salto sobre 50 %, que el punto medio impone como efecto lineal. El boosting cambia poco porque sus árboles ya recuperan esos umbrales. La conclusión (M3 es el mejor) no cambia, pero para una versión futura conviene adoptar la DTI categórica como especificación principal.

S2. Inclusión de la institución (estabilidad y población). La composición de instituciones cambia entre años; sin `lei`, el log-loss cambia en +0.0118 para M1 y en +0.0124 para M3. Que excluirla empeore el ajuste indica que el rechazo depende también de políticas propias de cada entidad; es una asociación, no una explicación causal.

6. Discusión y Conclusiones

Respuesta a la pregunta inicial. Al finalizar este estudio, comprobamos que las características financieras del solicitante y de la propiedad sí permiten anticipar el rechazo hipotecario de un año posterior superando ampliamente a la referencia histórica. En la evaluación definitiva de 2023, nuestro mejor modelo (M3 Gradient Boosting) alcanzó un AUC-ROC de 0.840 (0.8395) y redujo el log-loss en un 29.6 %. En la práctica, el poder predictivo del modelo se apoya principalmente en dos factores: el nivel de endeudamiento del cliente (DTI) y el criterio histórico de cada institución financiera (`lei`).

A pesar de estos buenos resultados, para interpretar el modelo de forma realista es necesario considerar sus principales **límites de generalización**:

- **Naturaleza retrospectiva de los datos:** El archivo histórico contiene los valores finales revisados al cierre del proceso. Variables como el DTI, el LTV o el valor de la propiedad pudieron haberse actualizado mientras se evaluaba al cliente. Además, los casos sin registro (`NA / Exempt`) pueden reflejar trámites que se interrumpieron a mitad de camino, donde el modelo pierde precisión al imputarlos con la mediana.
- **Alcance de la población:** El análisis se limita estrictamente a compras de vivienda principal con créditos convencionales en Colorado que llegaron a una resolución final. Quedan fuera las solicitudes retiradas por el cliente, expedientes incompletos y otros productos financieros.

- **Sensibilidad al contexto económico:** La reserva de prueba (2023) corresponde a un único año marcado por fuertes alzas en las tasas de interés. Esto provocó que el modelo sobreestimara levemente la tasa global de rechazo, demostrando que su calibración no es estática en el tiempo.
- **Asociación y no causalidad:** Los resultados reflejan patrones estadísticos de aprobación o rechazo, pero no miden causas directas, no predicen si el cliente caerá en mora en el futuro, ni permiten por sí solos dictaminar discriminación crediticia.

Utilidad práctica y conclusión del proyecto. Como conclusión general, este modelo no debe utilizarse como un filtro automático para rechazar personas de forma individual, ni aplicarse a ciegas sobre perfiles reales en un entorno real. Su verdadero valor dentro de una institución financiera es operar como una **herramienta de priorización inteligente**: permite ordenar la cartera de solicitudes según su nivel de riesgo para concentrar el esfuerzo de revisión manual en ese $\approx 23\,\%$ de alertas detectadas, ajustando el umbral de corte según la capacidad diaria del equipo de analistas (Figuras 7 y 8) y reentrenando el algoritmo año a año para mantener su vigencia operativa.

7. Reproducibilidad y contribuciones

Repositorio: Código fuente y análisis suplementario disponibles en GitHub [8].

Declaración de uso de IA. Claude (Anthropic), 10-11-2026: conversión del notebook del equipo en un flujo ejecutable (`main.py`), análisis adicionales (construcción de la muestra, bootstrap por institución, subgrupos y sensibilidades) y redacción del informe.

Contribuciones del equipo

- Desarrollo del flujo de código y modelamiento en Python (`main.py`). El análisis exploratorio, cálculo de intervalos de confianza por bootstrap y análisis de sensibilidad se desarrollaron en cuadernos Jupyter (fase de investigación), mientras que el flujo de limpieza, validación y evaluación final se consolidó en un script ligero de producción (`main.py`) (Julián Vargas y Álvaro Morales).
- Redacción de informe (Celeste Romero, Lucas González y Álvaro Morales).
- Auditoría de reproducibilidad, verificación de la ejecución del pipeline y la consistencia de los resultados (Álvaro Morales, Lucas González y Celeste Romero).
- Preparación de material para la presentación oral (Lucas González).

Referencias

[1] Breiman, L., Friedman, J., Olshen, R. y Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.

[2] Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1), 1–3.

[3] CFPB y FFIEC. *Public HMDA – LAR Data Fields*. `https://ffiec.cfpb.gov/documentation/publications/loan-level-datasets/lar-data-fields`.

[4] Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.

[5] James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2.ª ed.). Springer.

[6] Micci-Barreca, D. (2001). A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems. *SIGKDD Explorations*, 3(1), 27–32.

[7] Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[8] Vargas, J., González, L., Romero, C. y Morales, Á. (2026). *Proyecto-Final-Topicos-Rechazo-de-solicitudes-hipotecarias-en-Colorado* [Repositorio de código fuente]. GitHub. Recuperado de `https://github.com/JulianVargasJ/Proyecto-Final-Topicos-Rechazo-de-solicitudes-hipotecarias-en-Colorado.git`

Anexo técnico

A1. Decisiones de diseño y sus riesgos

1. **Codificación por objetivo sin validación cruzada interna.** La tasa de rechazo por institución y condado se calcula con las mismas filas de entrenamiento que luego la usan. Ninguna fila de validación o prueba ve su respuesta (no hay fuga hacia la evaluación), pero en categorías pequeñas la tasa incluye la propia respuesta y los modelos pueden sobrevalorar esa variable.
2. **Criterio de elección de hiperparámetros.** Se usa el AUC en el 20 % más reciente del entrenamiento, mientras la métrica principal es el log-loss; por eso la configuración elegida puede no ser la de menor log-loss. Ninguno de los dos puntos afecta la reserva 2023, que se evaluó una sola vez.
3. **DTI faltante imputada con la mediana.** Pierde que la DTI `NA` tiene una tasa de rechazo alta (subgrupo débil en la Tabla 8); S1 evalúa tratarla como categoría.

A2. Configuraciones elegidas en cada validación

Tabla 10: Configuración elegida por modelo y año de validación (criterio AUC interno).

Modelo	Año validado	Configuración elegida
M1 Logística L2	2020	C: 0.001
M1 Logística L2	2021	C: 0.001
M1 Logística L2	2022	C: 0.001
M2 Árbol podado	2020	max_depth: 10, min_samples_leaf: 500
M2 Árbol podado	2021	max_depth: 10, min_samples_leaf: 500
M2 Árbol podado	2022	max_depth: 10, min_samples_leaf: 100
M3 Gradient boosting	2020	learning_rate: 0.1, max_depth: 5, n_estimators: 100
M3 Gradient boosting	2021	learning_rate: 0.1, max_depth: 5, n_estimators: 100
M3 Gradient boosting	2022	learning_rate: 0.1, max_depth: 5, n_estimators: 100

A3. Heterogeneidad institucional

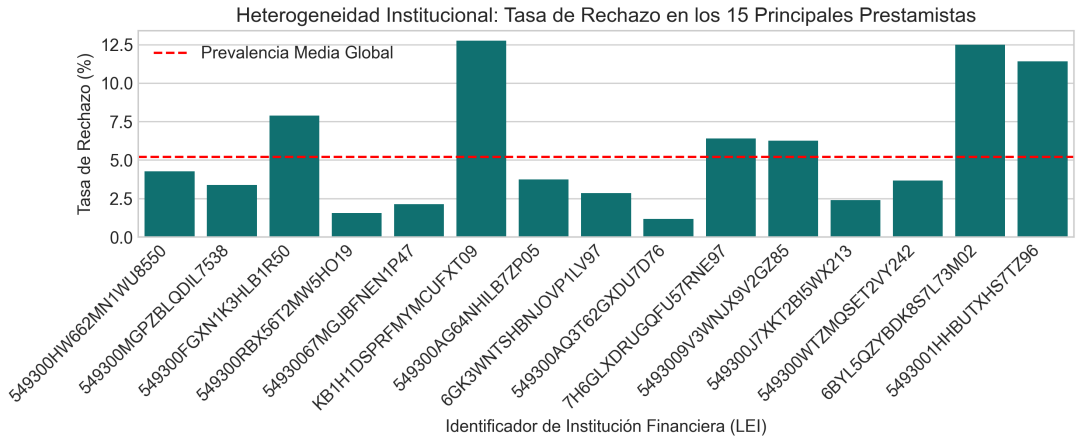


Figura 9: Tasa de rechazo de los 15 prestamistas con más solicitudes en 2019–2022; la línea roja es la tasa global.